

Big Data

Introdução ao Spark e ETL - Parte 2

Agenda

Funcionalidades do Spark

- Outras Fontes de Dados
- Machine Learning

Outras Fontes de Dados

- Você pode conectar com outras fontes de dados
- Tratar os dados como Dataframe
- Persistir como Tabela
- Também é possível Gravar Dados em outras fontes

- **Postgresql**

ler dados

```
resumo = spark.read.format("jdbc")  
.option("url","jdbc:postgresql://localhost:5432/vendas")  
.option("dbtable","Vendas")  
.option("user","postgres")  
.option("password","123456")  
.option("driver","org.postgresql.Driver")  
.load()
```

Outras Fontes de Dados

- **Postgresql**

transformar dados

```
vendadata = resumo.select("data","total").show()
```

- **Postgresql**

gravar dados na origem

```
vendadata.write.format("jdbc")  
.option("url","jdbc:postgresql://localhost:5432/vendas")  
.option("dbtable","vendadata")  
.option("user","postgres")  
.option("password","123456")  
.option("driver","org.postgresql.Driver")  
.save()
```

- **MongoDB**

ler dados

```
resumo = spark.read.format("com.mongodb.spark.sql.DefaultSource")  
.option("url","mongodb://localhost:27017/vendas")  
.load()
```

transformar dados

```
spark.sql("SELECT * FROM vendas").show(5)
```

Uso de Spark em ambientes de machine learning

- `spark.mllib`
- `spark.ml`
- ML baseado em RDD está descontinuado
- Implementações todas em DataFrames

Variáveis Independentes

Variável Dependente



CreditScore	Geography	Gender	Age	Tenure	Balance	NumOfProducts	HasCrCard	IsActiveMember	EstimatedSalary	Exited
619	France	Female	42	2	0	1	1	1	10134888	1
608	Spain	Female	41	1	8380786	1	0	1	11254258	0
502	France	Female	42	8	1596608	3	1	0	11393157	1
699	France	Female	39	1	0	2	0	0	9382663	0
850	Spain	Female	43	2	12551082	1	1	1	790841	0
645	Spain	Male	44	8	11375578	2	1	0	14975671	1
822	France	Male	50	7	0	2	1	1	100628	0
376	Germany	Female	29	4	11504674	4	1	0	11934688	1
501	France	Male	44	4	14205107	2	0	1	749405	0
684	France	Male	27	2	13460388	1	1	1	7172573	0
528	France	Male	31	6	10201672	2	0	0	8018112	0
497	Spain	Male	24	3	0	2	1	0	7639001	0
476	France	Female	34	10	0	2	1	0	2626098	0
549	France	Female	25	5	0	2	0	0	19085779	0
635	Spain	Female	35	7	0	2	1	1	6595165	0
616	Germany	Male	45	3	14312941	2	0	1	6432726	0
653	Germany	Male	58	1	13260288	1	1	0	509767	1
549	Spain	Female	24	9	0	2	1	1	1440641	0
587	Spain	Male	45	6	0	1	0	0	15868481	0
726	France	Female	24	6	0	2	1	1	5472403	0
732	France	Male	41	8	0	2	1	1	17088617	0
636	Spain	Female	32	8	0	2	1	0	13855546	0

- Normalmente todas as variáveis independentes devem compor uma mesma coluna
- Cria-se um vetor único, que é adicionado em nova coluna no DataFrame

One Hot Encoding

- Se o atributo tiver muitos valores, muitas colunas serão criadas
- Spark permite o uso de matriz esparsa
- Muitos valores zero que não são registrados

Pipelines

- Transformer: Transforma um DF em outro DF
- Estimator: Fit em DF para produzir um Transformer
- Pipeline: conecta Transformers e Estimators para Produzir modelo
- Parâmetros: Transformers e Estimators compartilham uma Api para definir parâmetros

Reutilização de Dataframe

- Cache – padrão em memória
- Persist – definido pelo usuário

StorageLevel

- MEMORY_ONLY: Padrão para RDD, porém se não caber na memória será reprocessado a cada consulta
- MEMORY_AND_DISK: Padrão para DataFrame. Armazena as partições que não cabem em memória em disco

Cache e Persist

DISK_ONLY

DISK_ONLY_2

DISK_ONLY_3

MEMORY_AND_DISK

MEMORY_AND_DISK_2

MEMORY_AND_DISK_SER

MEMORY_AND_DISK_SER_2

MEMORY_ONLY

MEMORY_ONLY_2

MEMORY_ONLY_SER

MEMORY_ONLY_SER_2

OFF_HEAP



FABRICIO TORQUATO

<https://www.linkedin.com/in/fabriciotorquato/>
fabricio.torquato@facens.br